

Математическое моделирование химико-технологических процессов

Лекция 2. Методы анализа данных и регрессионный анализ

Виталий Алексеевич Горбунов

Машинное обучение и покупка авто



Машина может	Машина не может
Предсказывать	Создавать новое
Запоминать	Резко поумнеть
Воспроизводить	Выйти за рамки задачи
Выбирать лучшее	Убить всех людей

https://vas3k.ru/

✓ Три составляющих машинного обучения:

- ***Данные (примеры)***
- Свойства/признаки/фичи
- Алгоритмы

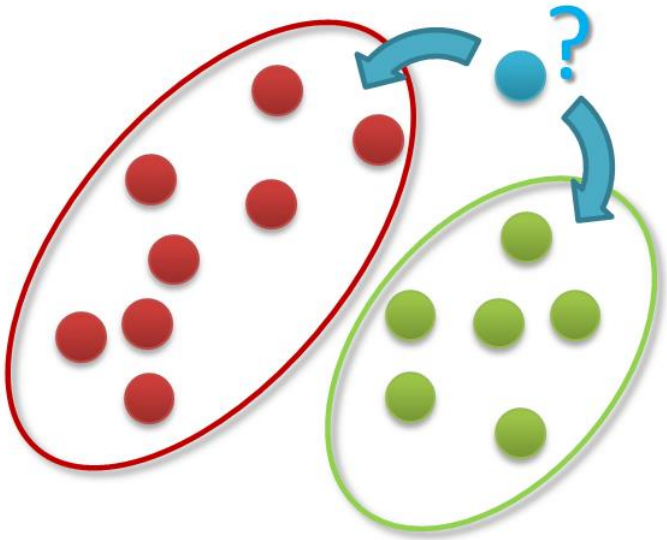
Классическое машинное обучение



https://vas3k.ru/

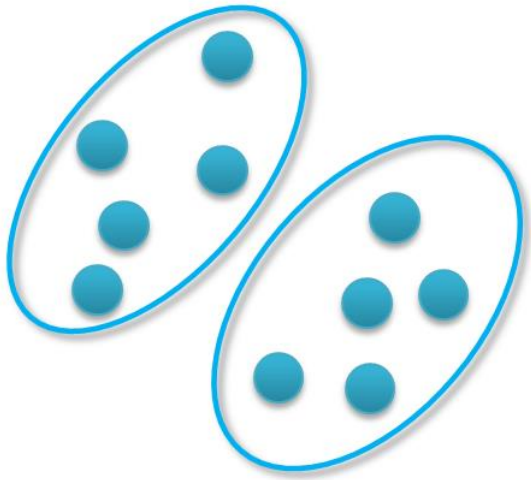
Классические методы анализа данных

Классификация



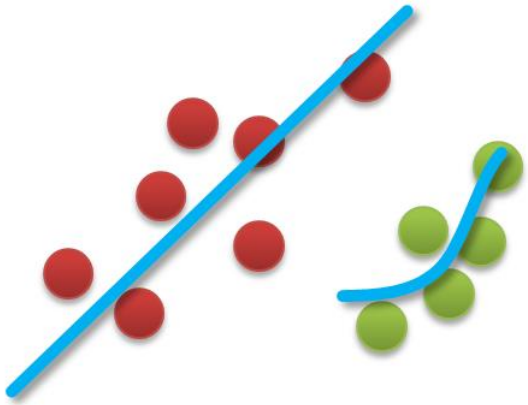
«Разложи носки по цвету» / «Распредели реакции в НП по тепловому эффекту»

Кластеризация



«Разложи похожие вещи по кучкам» / «Распредели реакторы на НПЗ по типу (какому именно – я не знаю)»

Регрессия



«Как зависит стоимость Toyota Land Cruiser от пробега?» / «Как степень конверсии вакуумного газойля зависит от высоты лифт-реактора?»

Задачи обработки данных и машинного обучения

- Используя известные данные, разработать модель и предсказать неизвестные данные.

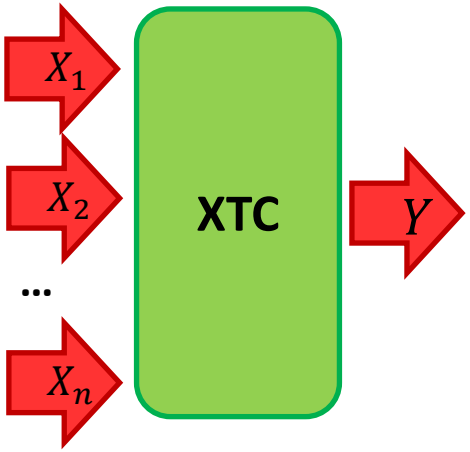
Вопрос	Алгоритм	Примеры
Это А или Б?	Классификация	Классификация объектов, процессов на два и более класса
Это странно?	Классификация Кластеризация Регрессия	Оценка рисков (отказ аппарата, выхода продукта плохого качества и т.п.)
Сколько?	Регрессия	Выход целевого продукта, расход теплоносителя, степень обессеривания бензина
Как это организовано?	Кластеризация	*Рекомендации* по условиям проведения реакции, по тех. режиму установки или аппарата
Что делать дальше?	Обучение с подкреплением	Системы управления (поддержание температуры, давления, расхода и т.п.)

Управление производством и машинное обучение



Регрессия - Задача «черного ящика»

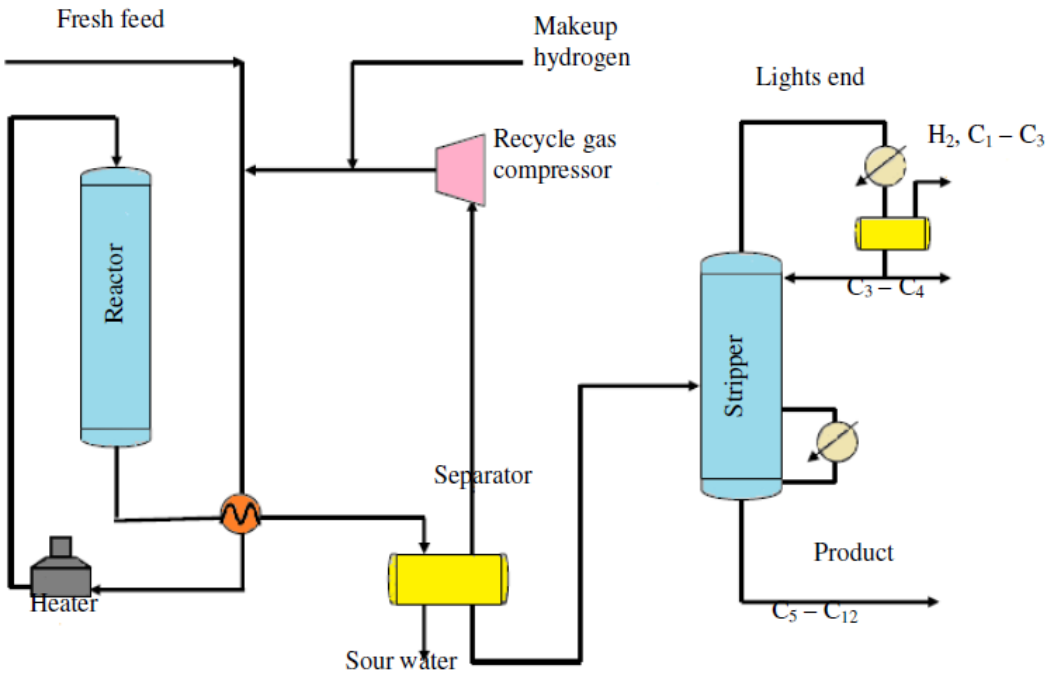
- Задача «черного ящика» - считается, что механизмы процессов, протекающих внутри объекта исследования, неизвестны, а имеются только соответствующие значения входных и выходных параметров.



- Требуется найти зависимость выходной переменной от входных

$$Y = f\left(X_1, X_2, ..., X_k\right)$$

Пример: гидроочистка бензиновой фракции





✓ Как скорость реакции (моль/с · кг Cat) зависит от давления (в атм ВСГ)?

Простейший случай – одна входная переменная

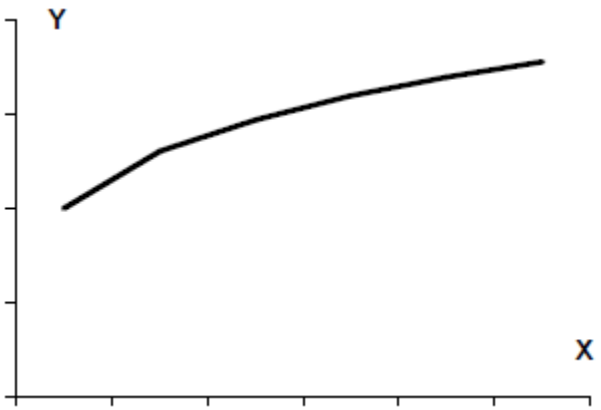
- Этапы решения задачи моделирования:
  - ***проведение эксперимента;***
  - выбор вида эмпирической зависимости;
  - нахождение параметров выбранной зависимости;
  - исследование модели и выводы.

$$Y = f(X)$$

X	x_1	x_2	…	x_n
Y	y_1	y_2	…	y_n

- Например, зависимость скорости реакции гидроочистки бензиновой фракции от давления ВСГ в реакторе:

r, моль/с кг Cat	P, МПа
0.0192	1.382
0.0234	2.075
0.0258	2.431
0.0281	2.762
0.0318	3.5
0.0319	3.833
0.0334	4.129



Регрессионный анализ

- ***Регрессионный анализ*** – это статистический метод для определения параметров модели.

- Наиболее простой формой регрессионного анализа является линейный регрессионный анализ модели с одной переменной.

$$y = \beta_0 + \beta_1 x + \varepsilon$$

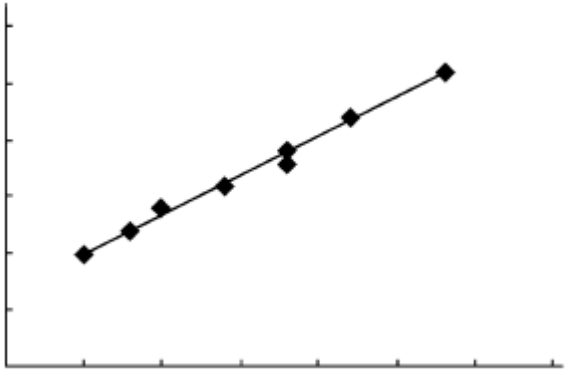
y – зависимая переменная - отклик системы - выходная переменная

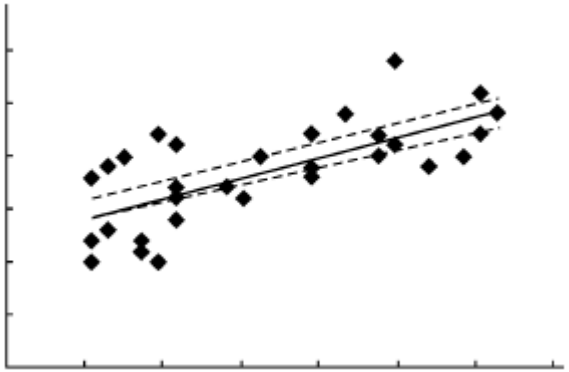
x – независимая переменная - предиктор - входная переменная

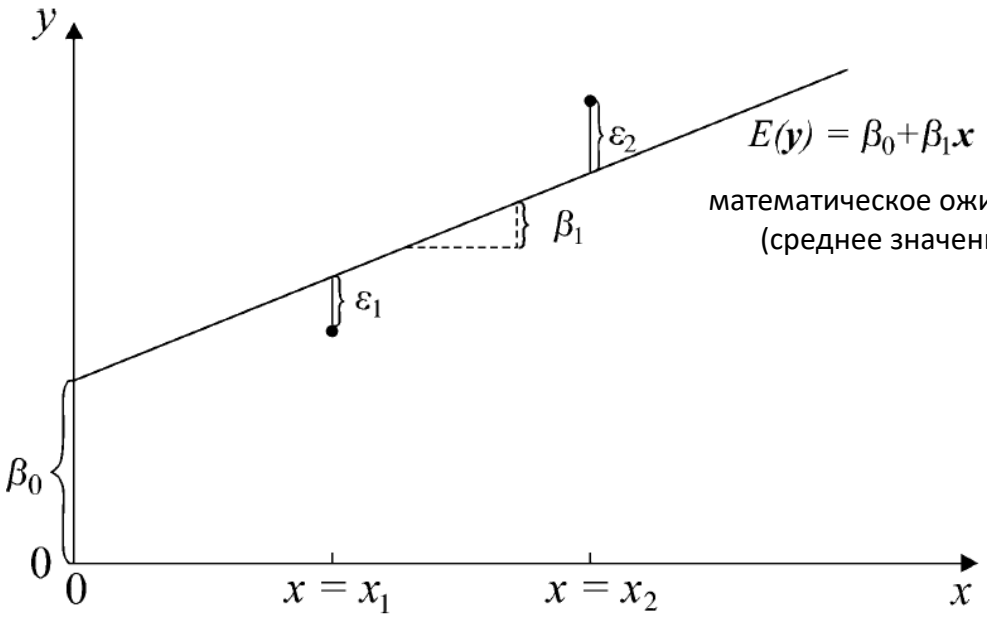
β – параметры модели

ε – стохастическая (вероятностная) часть, описывает случайную ошибку (погрешность)

Простая линейная регрессия







$E(y) = \beta_0 + \beta_1 x$

математическое ожидание
(среднее значение)

Линейная и нелинейная регрессия

- Множественная линейная модель $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \ldots + \beta_k x_k + \varepsilon$
- Полиноминальная модель $y = \beta_0 + \beta_1 x + \beta_2 x^2 + \beta_3 x^3 + \varepsilon$
- Синусоидальная модель $y = \beta_0 + \beta_1 \sin(\theta) + \beta_2 \cos(\theta) + \varepsilon$

✓ Модели являются линейными, поскольку параметры входят в модель в степенях не выше единицы. То есть,

$$\frac{dy}{d\beta} = f(x)$$

- Нелинейная модель $y = \beta_0 e^{-\beta_1 / Rx}$

$$\frac{dy}{d\beta_1} = \frac{-\beta_0}{Rx} e^{-\beta_1 / Rx}$$

$$y = \beta_0 + \beta_1 \sin(\beta_2 \theta) + \beta_3 \cos(\beta_4 \theta) + \varepsilon$$

Общий случай - вид эмпирической зависимости

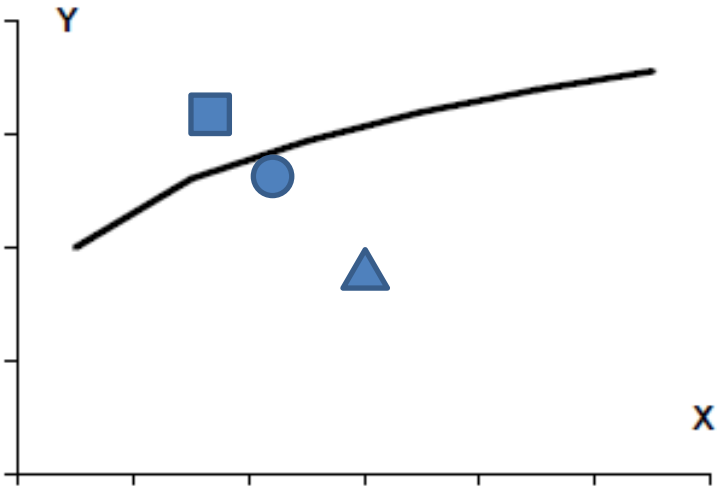
✓ В общем случае необходимо подобрать зависимость, которая могла бы описать экспериментальные данные. ***Для монотонных зависимостей:***

№	Формула	X_k	Y_k	Приведение к линейному виду
1	$Y = a \cdot X^b$	$\sqrt{X_1 \cdot X_n}$	$\sqrt{Y_1 \cdot Y_n}$	$U=A+bZ;$ $U=\lg Y;\ A=\lg a;\ Z=\lg X$
2	$Y = a \cdot b^X$	$(X_1+X_n)/2$	$\sqrt{Y_1 \cdot Y_n}$	$U=A+BX;$ $U=\lg Y;\ A=\lg a;\ B=\lg b$
3	$Y=\frac{1}{a+b \cdot X}$	$(X_1+X_n)/2$	$\frac{2 \cdot Y_1 \cdot Y_n}{Y_1+Y_n}$	$U=a+bX;\quad U=1/Y$
4	$Y=a+b \cdot \lg X$	$\sqrt{X_1 \cdot X_n}$	$(Y_1+Y_n)/2$	$Y=a+bZ;\quad Z=\lg X$
5	$Y = a + \frac{b}{X}$	$\frac{2 \cdot X_1 \cdot X_n}{X_1+X_n}$	$(Y_1+Y_n)/2$	$Y=a+bZ;\quad Z=1/X$
6	$Y = \frac{a \cdot X}{b+X}$	$\frac{2 \cdot X_1 \cdot X_n}{X_1+X_n}$	$\frac{2 \cdot Y_1 \cdot Y_n}{Y_1+Y_n}$	$U=A+BZ;\ U=1/Y;\ Z=1/X;$ $A=1/a;\ B=b/a$

Вид эмпирической зависимости

✓ Выбор вида зависимости методом средних точек (для равномерно непрерывной зависимости в исследуемом интервале):

- Расчет координат средних точек X_k и Y_k;
- Нанесение средних точек на экспериментальную зависимость;
- Выбор функционального вида зависимости, средняя точка которого лежит ближе всего к экспериментальной кривой.



$y = \beta_0 + \beta_1 x$

$y = \beta_0 x^{\beta_1}$

$y = \dfrac{\beta_0 x}{\beta_1 + x}$

Параметры выбранной зависимости

✓ Необходимо определить параметры искомой зависимости β_0, β_1 таким образом, чтобы расчетная кривая лежала как можно ближе к экспериментальной кривой:

- ***Критерий близости:*** минимум суммы квадратов отклонений между экспериментальными и расчетными значениями

$$S = \sum_{i=1}^{n} \left(Y_i^{\exp} - Y_i^{calc} \right)^2 = \sum_{i=1}^{n} \left(Y_i - \beta_0 - \beta_1 X_i \right)^2 \to \min$$

- ***Условие минимума S:*** равенство нулю производных по параметрам β_0, β_1

$$\begin{cases} \dfrac{\partial S}{\partial \beta_0} = 0 \\ \dfrac{\partial S}{\partial \beta_1} = 0 \end{cases}$$

- При нахождении параметров нелинейных функциональных зависимостей необходимо сначала привести их к линейному виду.

Параметры выбранной зависимости

- ***Условие минимума S:*** равенство нулю производных по параметрам ***a*** и ***b.***

$$S = \sum_{i=1}^{n} \left(Y_i - \beta_0 - \beta_1 X_i \right)^2$$

$$\frac{dS}{d\beta_0} = 0 \quad и \quad \frac{dS}{d\beta_1} = 0$$

$$\begin{cases} \beta_0 \cdot n + \beta_1 \cdot [X] = [Y] \\ \beta_0 \cdot [X] + \beta_1 \cdot [X^2] = [X \cdot Y] \end{cases}$$

$$[X] = \sum_{i=1}^{n} X_i, \; [Y] = \sum_{i=1}^{n} Y_i, \; [X^2] = \sum_{i=1}^{n} X_i^2, \; [X \cdot Y] = \sum_{i=1}^{n} X_i \cdot Y_i$$

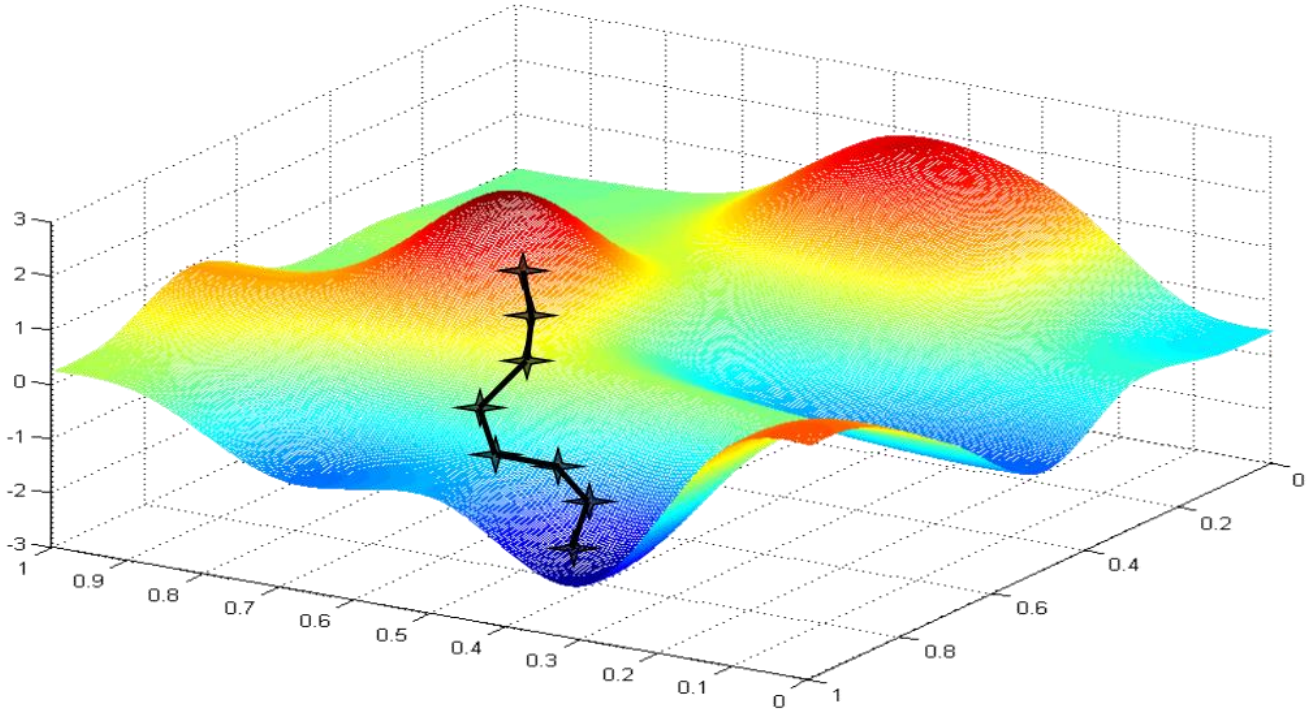
✓ Решив систему уравнений, получаем искомые значения параметров.

- Получаем расчетные значения подстановкой в найденную формулу экспериментальных значений входной величины;
- Полученные значения наносим на график с экспериментальными данными;
- Делаем вывод об адекватности модели.

Метод градиентного спуска

$$S = \sum_{i=1}^{n} \left(Y_i^{\exp} - Y_i^{calc} \right)^2 = \sum_{i=1}^{n} \left(Y_i - \beta_0 - \beta_1 X_i \right)^2 \to \min$$

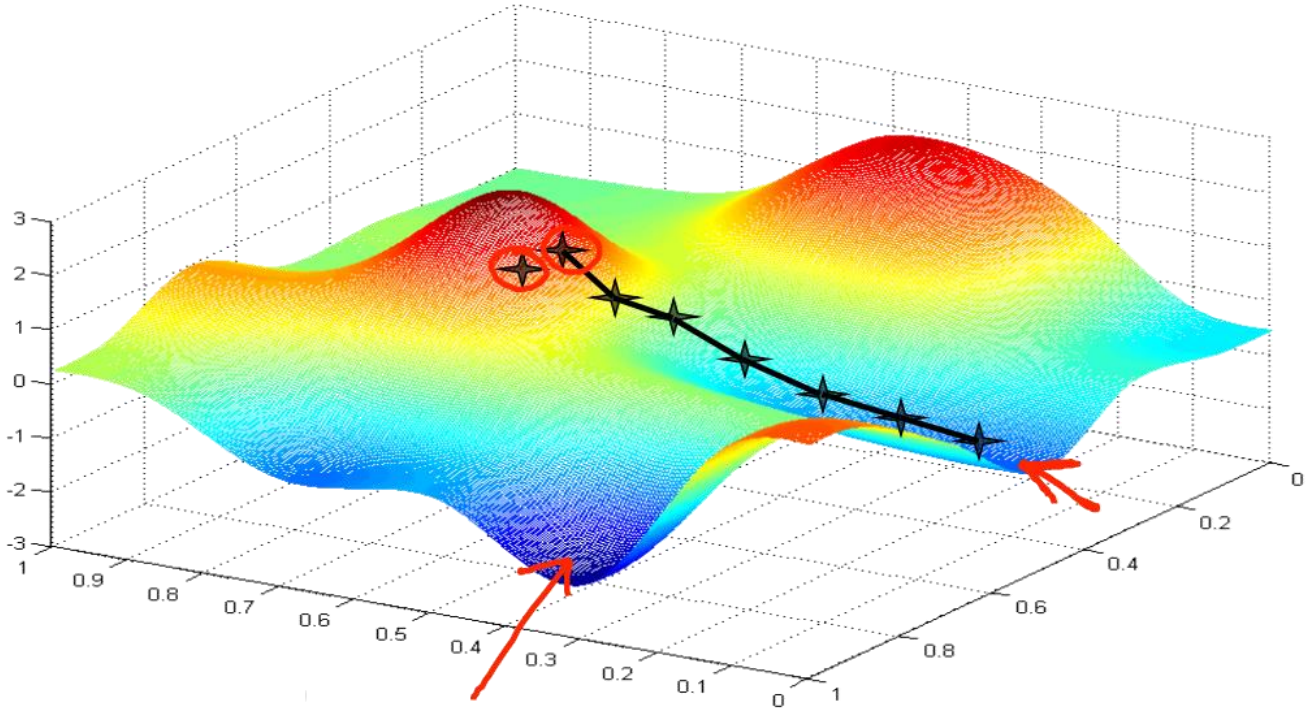
- Начинаем с произвольных значений параметров (β_0, β_1)
- Продолжаем изменять β_0, β_1 чтобы уменьшить $S(\beta_0, \beta_1)$ до тех пор пока предположительно не достигнем минимума



Метод градиентного спуска

$$S = \sum_{i=1}^{n} \left(Y_i^{\exp} - Y_i^{calc} \right)^2 = \sum_{i=1}^{n} \left(Y_i - \beta_0 - \beta_1 X_i \right)^2 \to \min$$

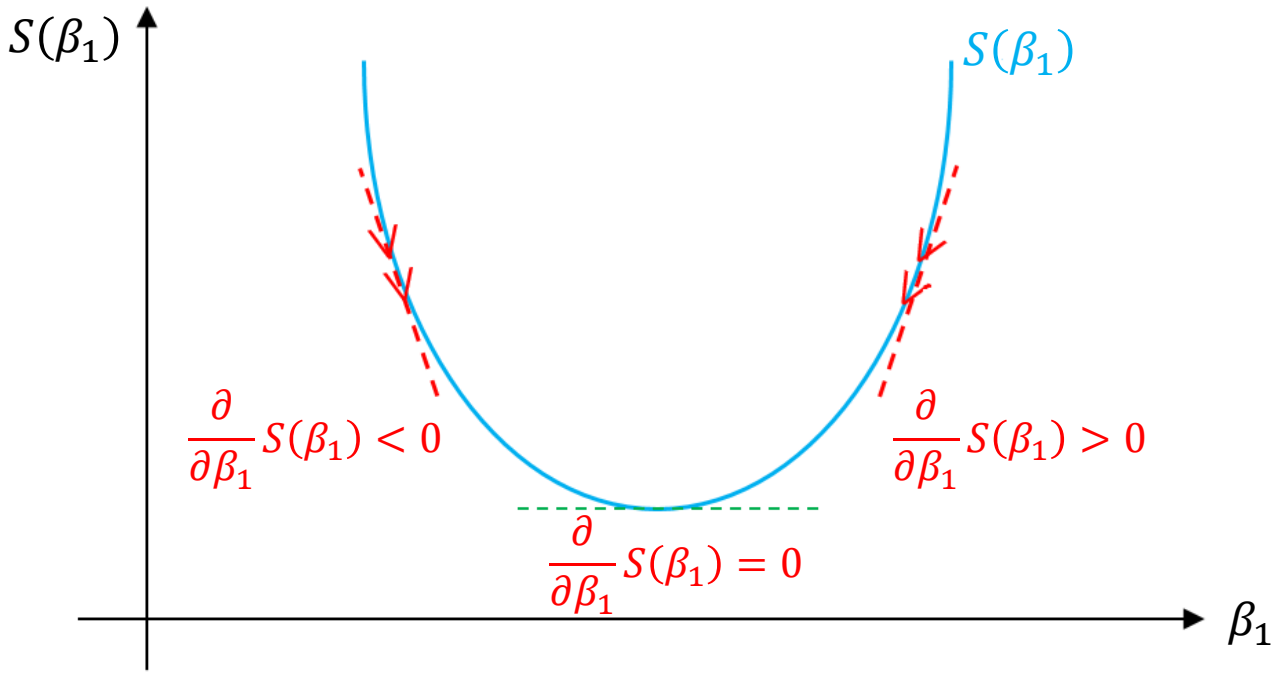
- Начинаем с произвольных значений параметров (β_0, β_1)
- Продолжаем изменять β_0, β_1 чтобы уменьшить $S(\beta_0, \beta_1)$ до тех пор пока предположительно не достигнем минимума



Метод градиентного спуска - алгоритм

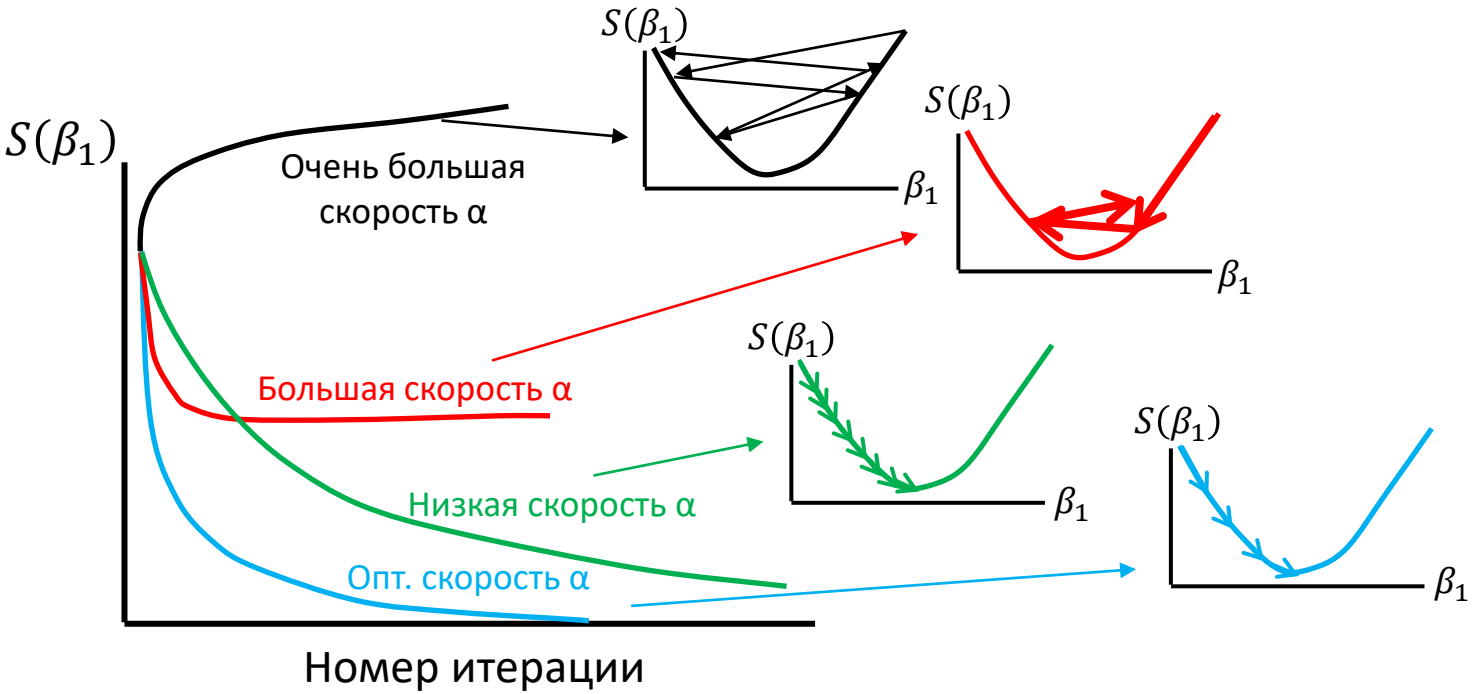
$$S = \sum_{i=1}^{n} \left(Y_i^{\exp} - Y_i^{calc} \right)^2 = \sum_{i=1}^{n} \left(Y_i - \beta_0 - \beta_1 X_i \right)^2 \to \min$$

- Повторять $\beta_i := \beta_i - \alpha \frac{\partial}{\partial \beta_i} S(\beta_0, \beta_1)$ до достижения сходимости (одновременно обновляются значения *i*=0 и *i*=1)

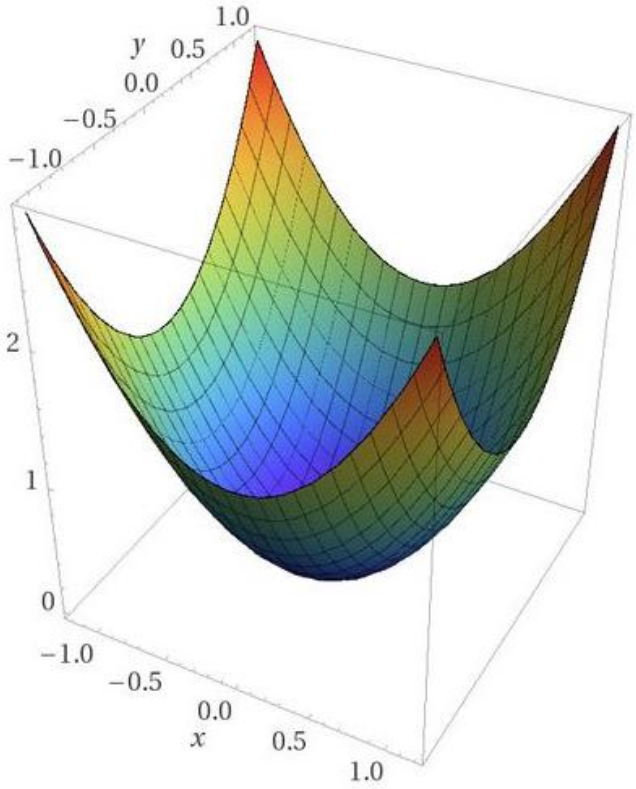


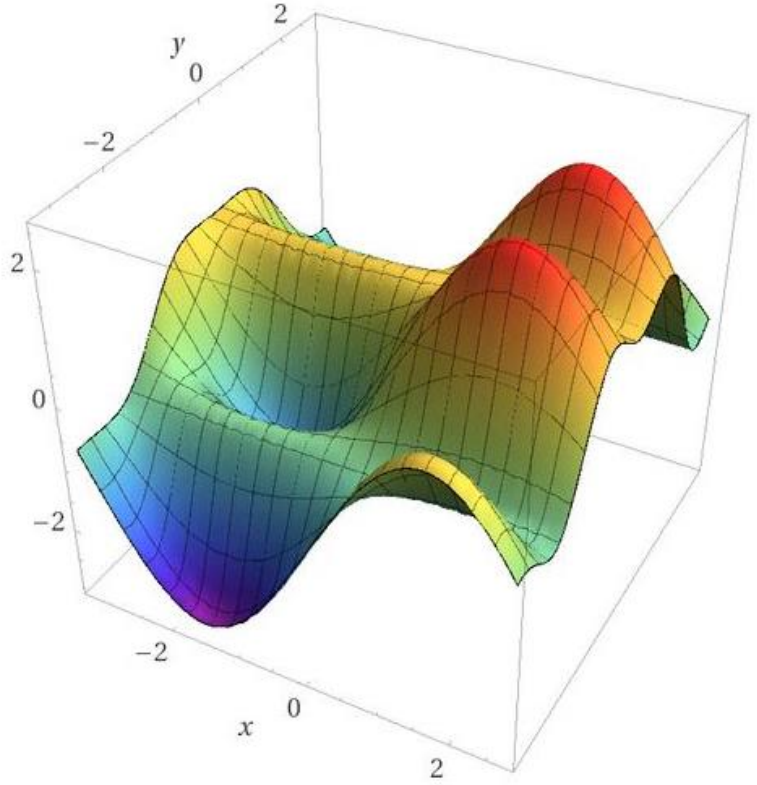
Метод градиентного спуска – «скорость обучения»

- Повторять $\beta_i := \beta_i - \alpha \frac{\partial}{\partial \beta_i} S(\beta_0, \beta_1)$ до достижения сходимости (одновременно обновляются значения *i*=0 и *i*=1)



Метод градиентного спуска





Линейная и нелинейная регрессия - Soft

✓ Современные программные средства позволяют решить задачу регрессии значительно проще:

- **Excel – пакет «Анализ данных» (меню «Сервис»)**
- Matlab – пакет Curve Fitting
- **Python – библиотеки NumPy, SciPy и SciKit-Learn**
- STATISTICA

Методы оценки адекватности модели

- Абсолютное отклонение (Mean Absolute Error)

$$MAE = \frac{1}{n}\sum_{i=1}^{n}\left|y_i^{exp} - y_i^{calc}\right|$$

- Средний квадрат отклонения (Mean Squared Error)

$$MSE = \frac{1}{n}\sum_{i=1}^{n}\left(y_i^{exp} - y_i^{calc}\right)^2$$

- Среднеквадратичное отклонение (Root Mean Squared Error)

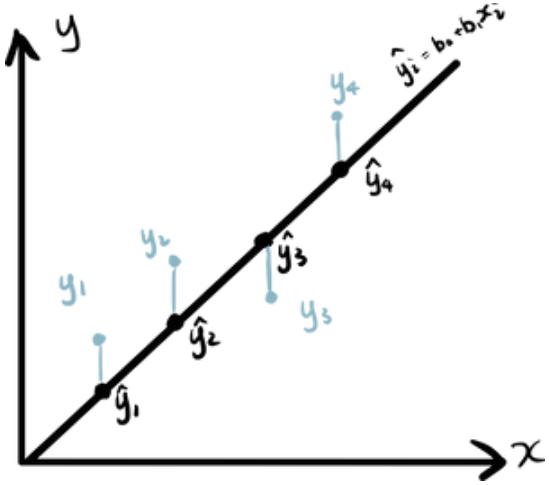
$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}\left(y_i^{exp} - y_i^{calc}\right)^2}$$

Коэффициент детерминации модели (R^2)

$$R^2 = 1 - \frac{RSS}{TSS}$$ - Показывает какую долю отклонений объясняет модель

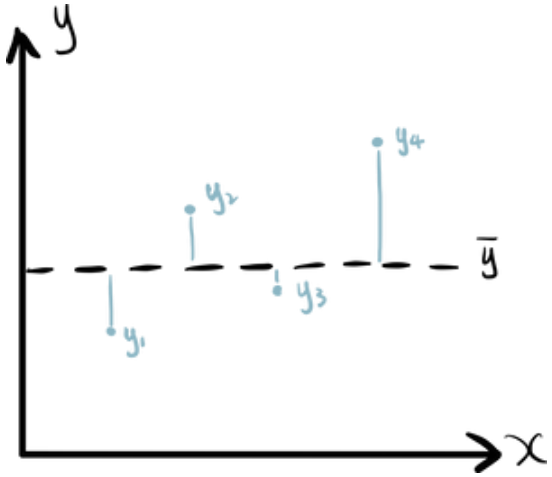
- Остаточная сумма (Residual Sum of Squares)

$$RSS = \sum_{i=1}^{n} \left(y_i^{exp} - y_i^{calc}\right)^2$$

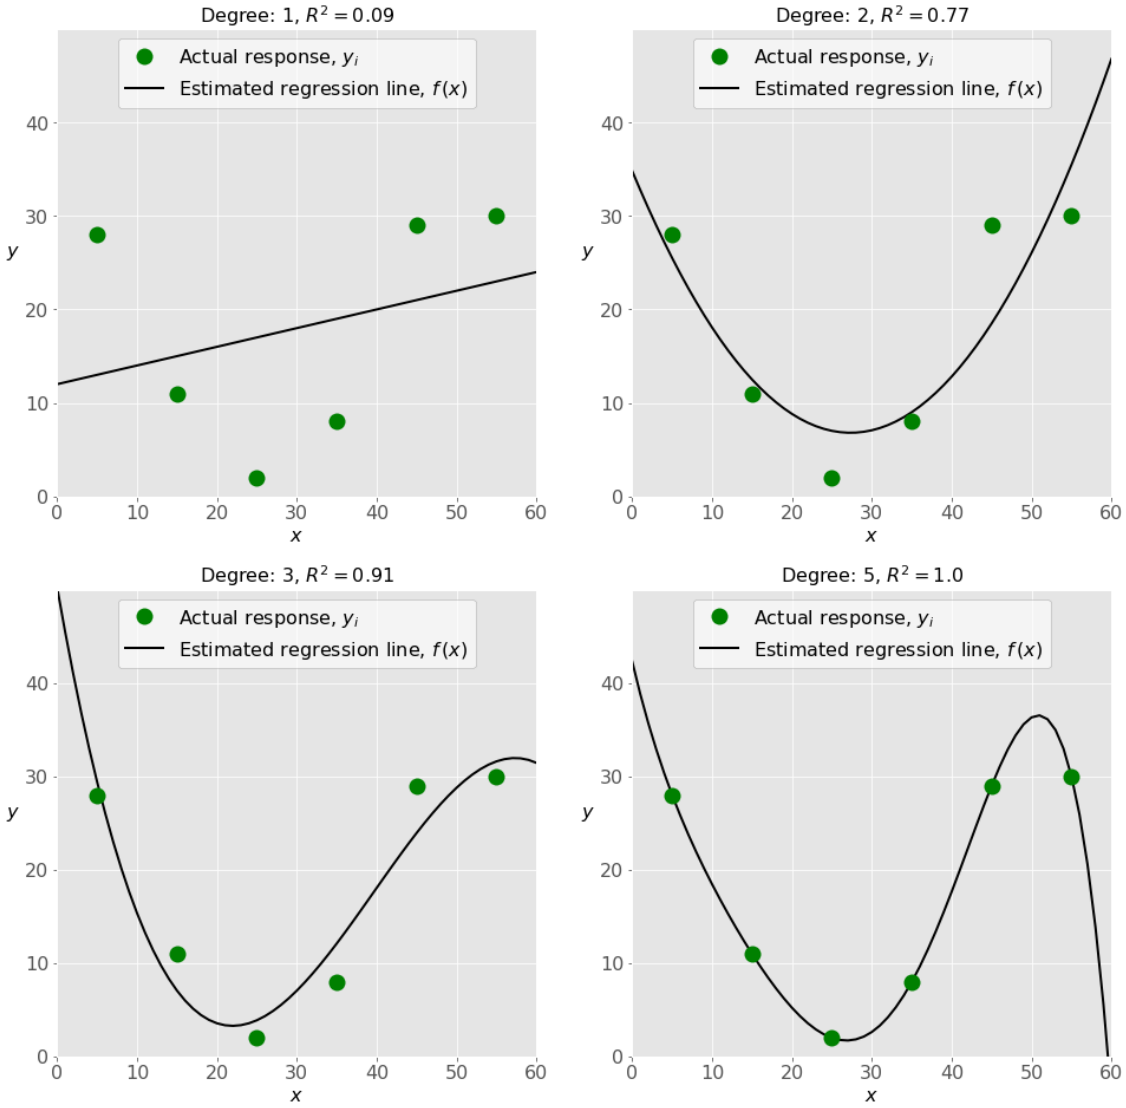


- Полная дисперсия (Total Sum of Squares)

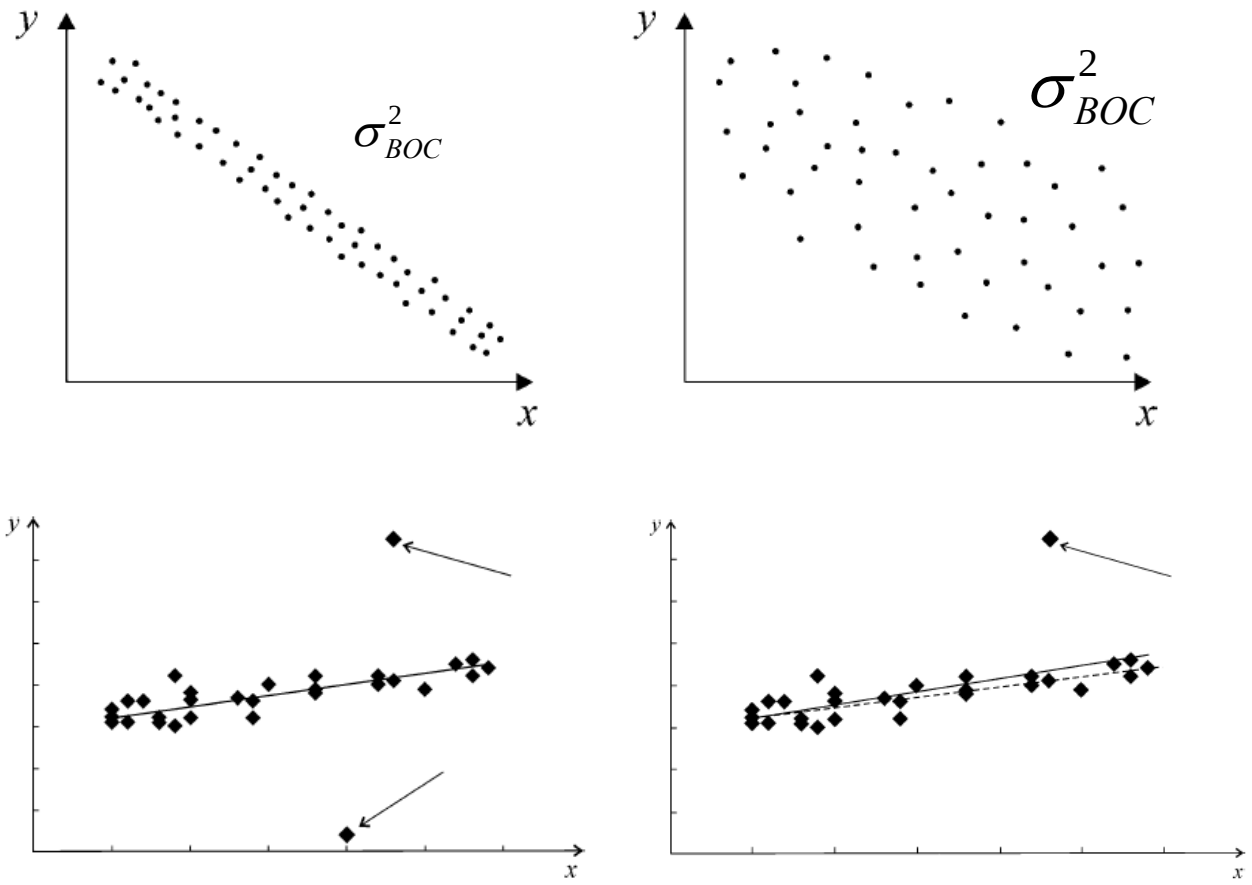
$$TSS = \sum_{i=1}^{n} \left(y_i^{exp} - \overline{y^{exp}}\right)^2$$



Коэффициент детерминации модели (R^2)

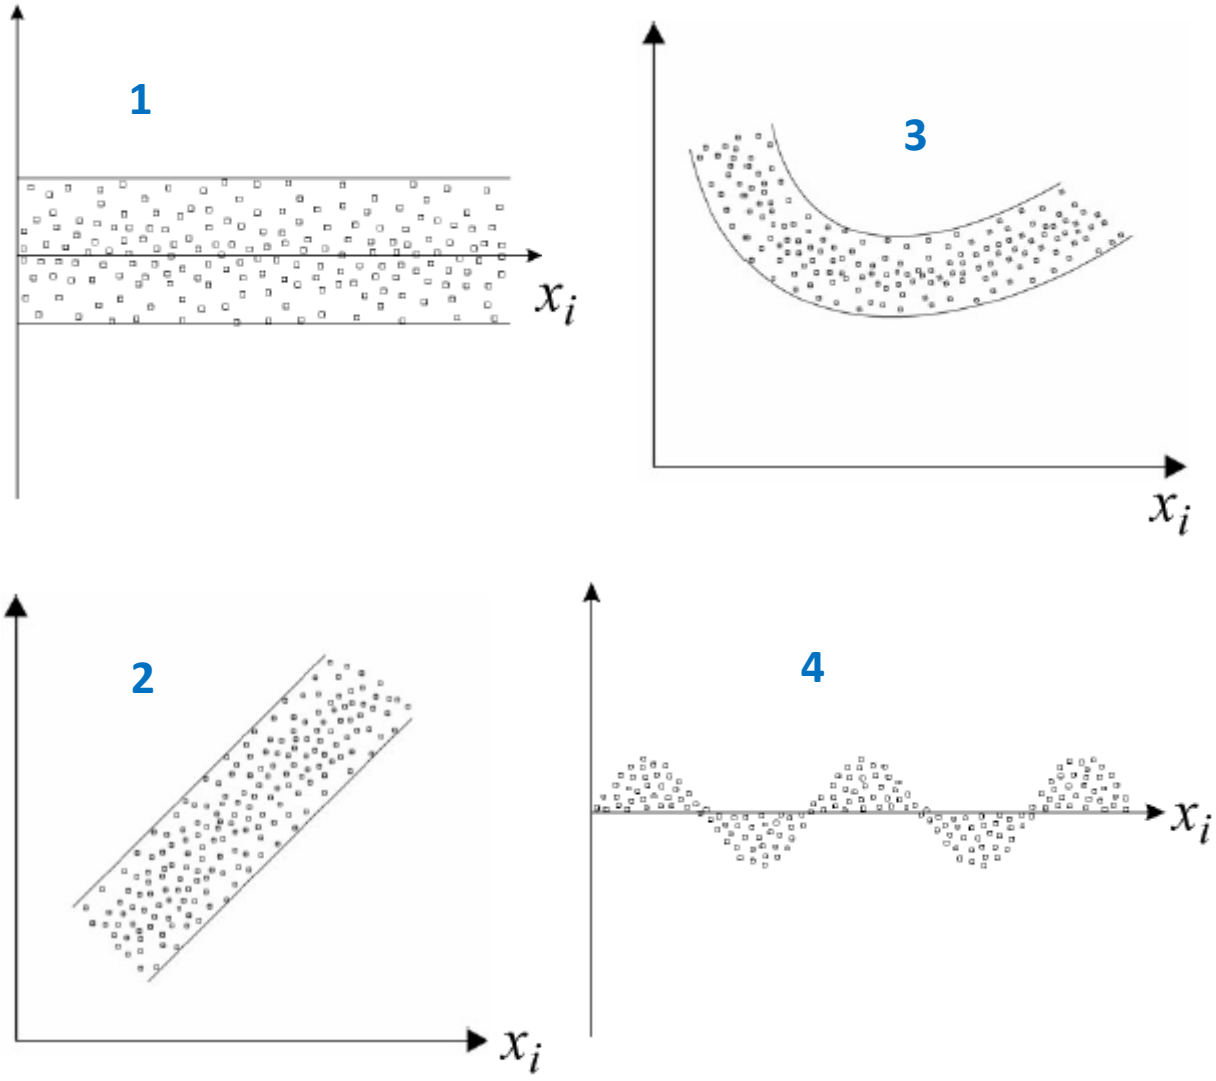


Методы оценки адекватности модели – дисперсия



✓ «Промахи» исключаются, только при условии четкого обоснования.

График остатков



$$\text{Остаток} = y_i^{exp} - y_i^{calc}$$

1. Полностью случайное распределение ошибок
2. Нужно добавить линейную часть
3. Нужно добавить квадратичную часть
4. Нужно добавить синусоидальную часть

Читать

- A. Rasmuson – Глава #7.
- A.C. Гумеров – Главы #8 и #9 (пункт 9.1)

